Analyse Lexicale

CS410 - Langages et Compilation

Julien Henry
Catherine Oriat

Grenoble-INP Esisar

2012-2013

Analyse Lexicale

Lexicographie : décrit la forme des mots du langage.

Analyse Lexicale : transforme une suite de *caractères* en une suite de *mots*.

Les mots peuvent être décrit par des *Langages réguliers*.

programme source (suite de caractères)
exemple : `val := val + 1;`

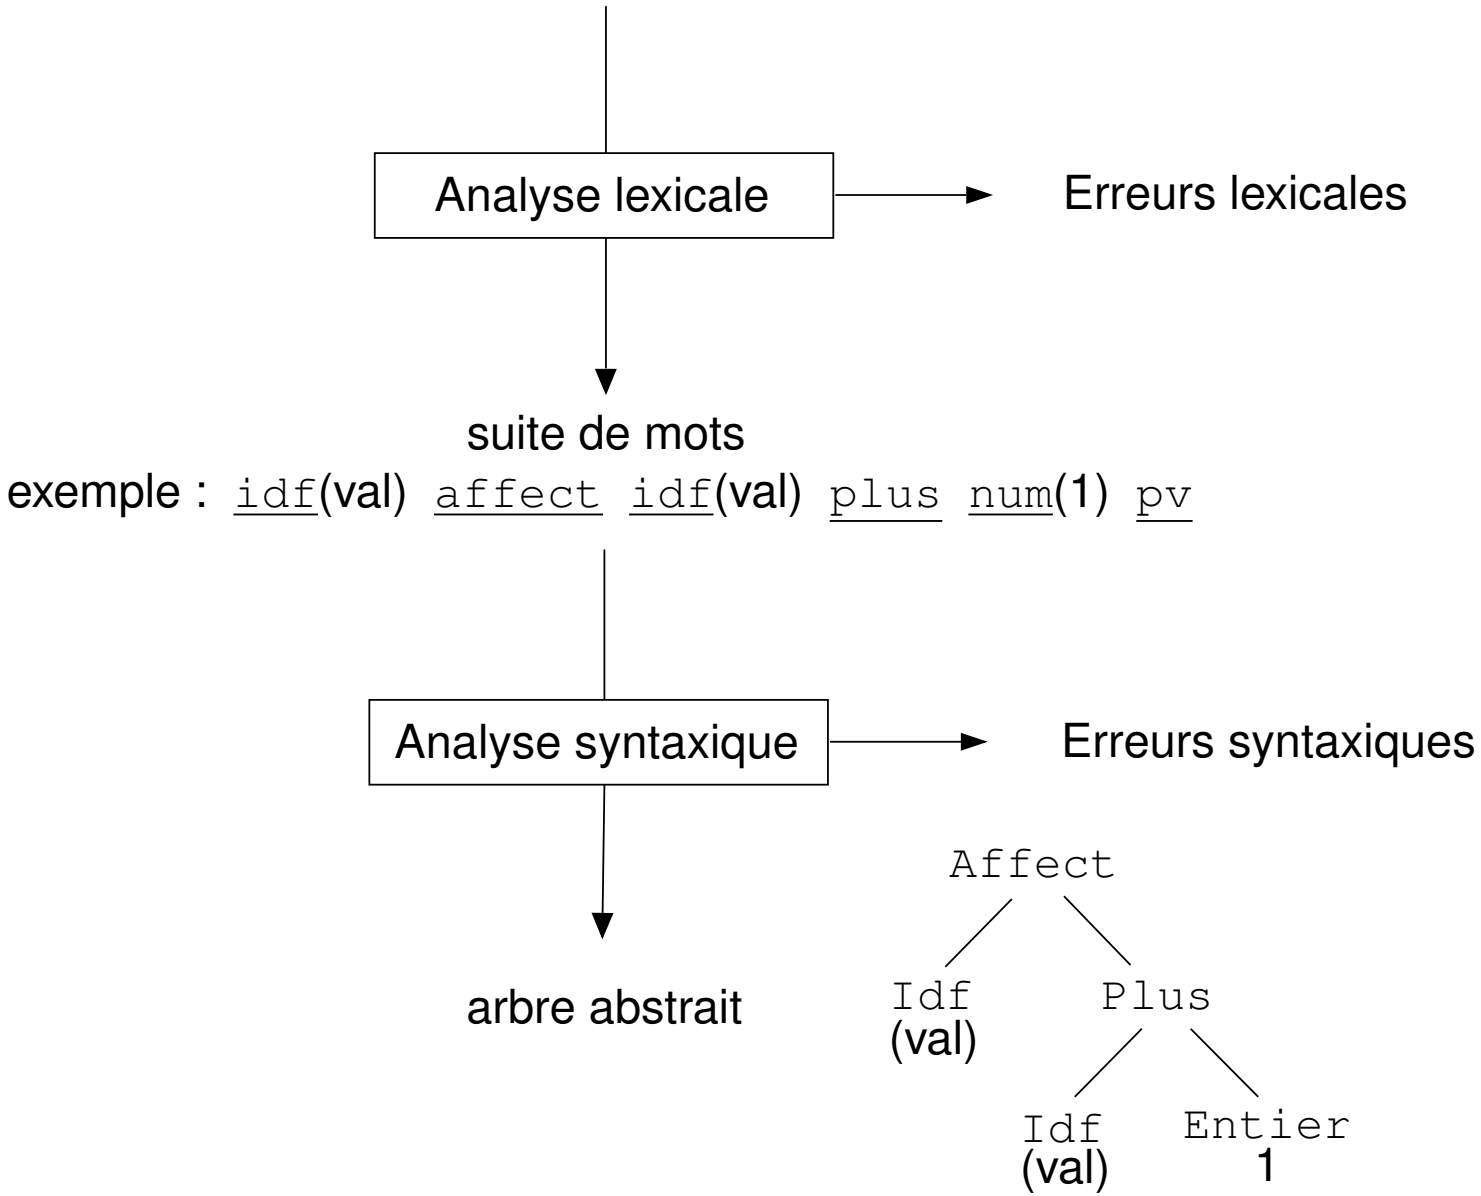

Rôle de l'Analyse Lexicale

- Supprime les espaces, retours à la ligne, tabulations, commentaires
- identifie les *mots réservés* et les *identificateurs*.

Ces mots sont appelés les *lexèmes* (ou *token*).

Exemple

Un exemple de programme en Jcas :

```
delta := b*b - 4*a*c;
```

idf(delta) affect idf(b) mult idf(b)
moins num(4) mult idf(a) mult idf(c)

Lexèmes : idf, affect, mult, moins, num

Vocabulaire Terminal

L'ensemble des lexèmes forme le vocabulaire terminal du langage.

Exemple :

$$
\begin{array}{lcl}
\text{Exp} & \rightarrow & \text{Exp } \underline{\texttt{plus}} \text{ Terme} \\
 & & \mid \text{Exp } \underline{\texttt{moins}} \text{ Terme} \\
 & & \mid \text{Exp } \underline{\texttt{mult}} \text{ Terme} \\
 & & \mid \text{Terme} \\
\text{Terme} & \rightarrow & \underline{\texttt{idf}} \mid \underline{\texttt{num}} \mid \underline{\texttt{(}} \text{ Exp } \underline{\texttt{)}}
\end{array}
$$

Identificateurs en Jcas

Lettre = { 'a', 'b', . . . , 'z', 'A', . . . 'Z'}
Chiffre = { '0', '1', . . . , '9'}
Idf = Lettre (Lettre + Chiffre + '_')*

On utilise des langages *réguliers* : cela permet d'obtenir des algorithmes de reconnaissance efficaces.

Reconnaisseur de Langages Réguliers

Definition (Reconnaisseur)

Un reconnaisseur pour L est un programme prenant en entrée une chaîne c et qui retourne $c \in L$.

Pour écrire un reconnnaisseur, on utilise un automate *déterministe*, si possible *minimal*.

Exemple

Automate reconnaisseur de l'expression régulière : $0 + 1(0 + 1)^*$.

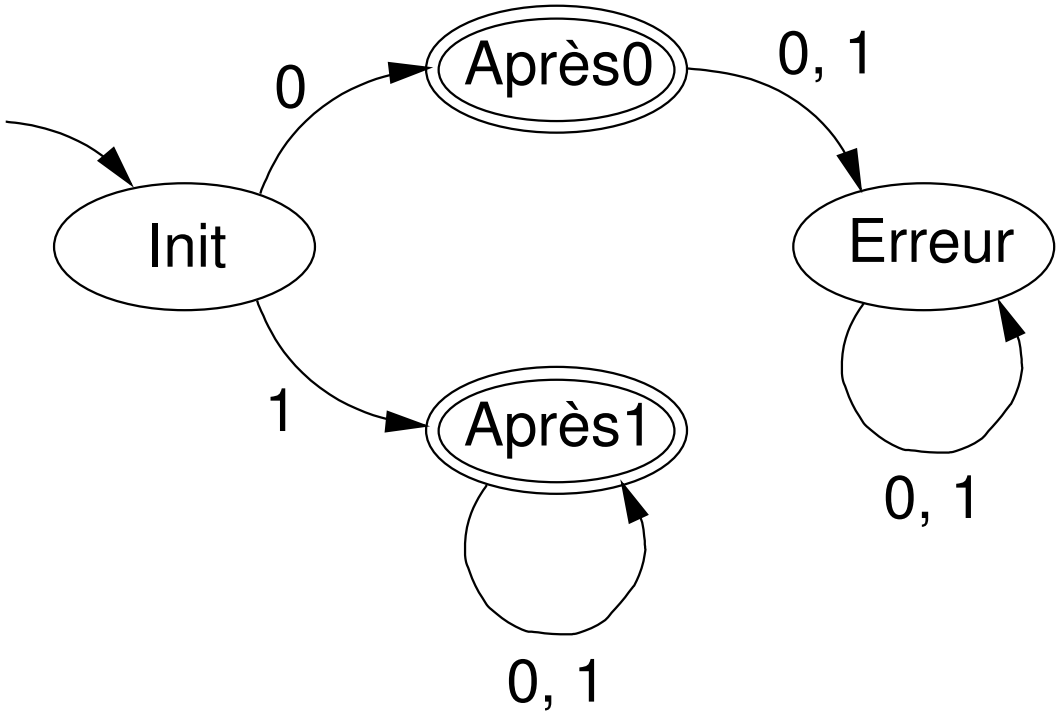

Algorithme reconnaisseur

Il existe 3 méthodes automatiques pour programmer un algorithme reconnaisseur à partir d'un automate :

1. utilisation d'une variable d'état, codage des transitions
2. codage des transitions par un tableau
3. codage avec des étiquettes et des branchements

Variable d'état, codage des transitions

- On définit un type Etat de l'automate.
- On utilise une variable de type état pour définir l'état courant.
- On code les transitions de l'automate avec un grand "switch" sur la valeur de l'état courant.

Variable d'état, codage des transitions

```
public enum Etat {Init, Apres0, Apres1, Erreur;}
public reconnaisseur {
  Etat E = Init; char C = lire_car();
  while (C != '#') {
    switch (Etat) {
      case Init:
        if (C == '0') E = Apres0; else E = Apres1;
        break;
      case Apres0:
        E = Erreur;
      default: break;
    }
    C = lire_car();
  }
  if (!(E == Apres0 || E == Apres1))
    {System.out.println("ERREUR");}
}
```

Codage par label et branchements

- Chaque état de l'automate est codé par un label.
- Chaque transition de l'automate est codée par une instruction `goto`

Codage par label et branchements

```
void reconnaisseur () {
        char c;
        bool ok;
Init:
        c = lire_car();
        if (c=='0') goto Apres0;
        if (c=='1') goto Apres1;
        ok = false; goto Fin;
Apres0:
        c = lire_car();
        if (c=='#') {ok = true; goto Fin};
        goto Erreur;
Apres1:
        ...
Fin:
        if (ok) printf("chaine reconnue")
        else    printf("chaine non reconnue")
}
```

Ecriture d'un analyseur lexical

Definition (analyseur lexical)

Un analyseur lexical est un programme qui lit des caractères en entrée et fournit des lexèmes (token).

Propriétes de l'analyseur

- On veut reconnaître le préfixe le plus long possible :
  d, *de*, *del*, *delt* sont des identificateurs possibles, mais on veut obtenir l'identificateur *delta*.
- Enchaînement de plusieurs unités lexicales :
  La fin d'une unité lexicale est détectée soit par un séparateur (espace), soit par le début de l'unité lexicale suivante.
  Exemple : b*b - 4*a*c
- Détection des mots réservés :
  Il faut reconnaître les mots réservés (begin, end, etc.). On construit une table contenant tous ces mots ainsi que son code associé , et on recherche si le mot lu appartient à cette table.

Lexème

L'analyse lexicale fournit le type de lexème (`begin`, `end`, `idf`, etc), mais aussi des informations supplémentaires.

```
public enum Code_lex {Begin_lex, Affect, Num, ...}

public class Lexeme {
        // code du lexeme
        Code_lex code;
        // chaine correspondant a l'unite lexicale
        String chaine;
        // numeros de ligne et colonne du lexeme
        int num_ligne, num_colonne;
}
```

Extension des automates

Pour traiter l'enchaînement de plusieurs unités lexicales sans séparateur, on introduit des transitions dans l'automate qui ne consomment pas le symbole courant.

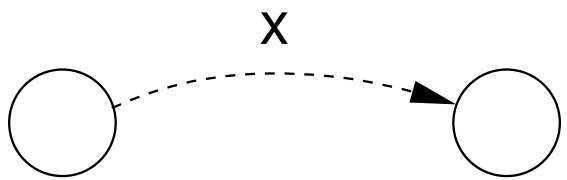

Exemple

On considère le langage de lexicographie :

- les commentaires commencent par “/*” et finissent par “*/”
- on a les signes “ :”, “ :=”, “/” et “+”
- les séparateurs sont l’espace, le retour à la ligne et les commentaires
- les identificateurs sont définis par $Idf = Lettre^{+}$
- les entiers sont définis par $Num = Chiffre^{+}$

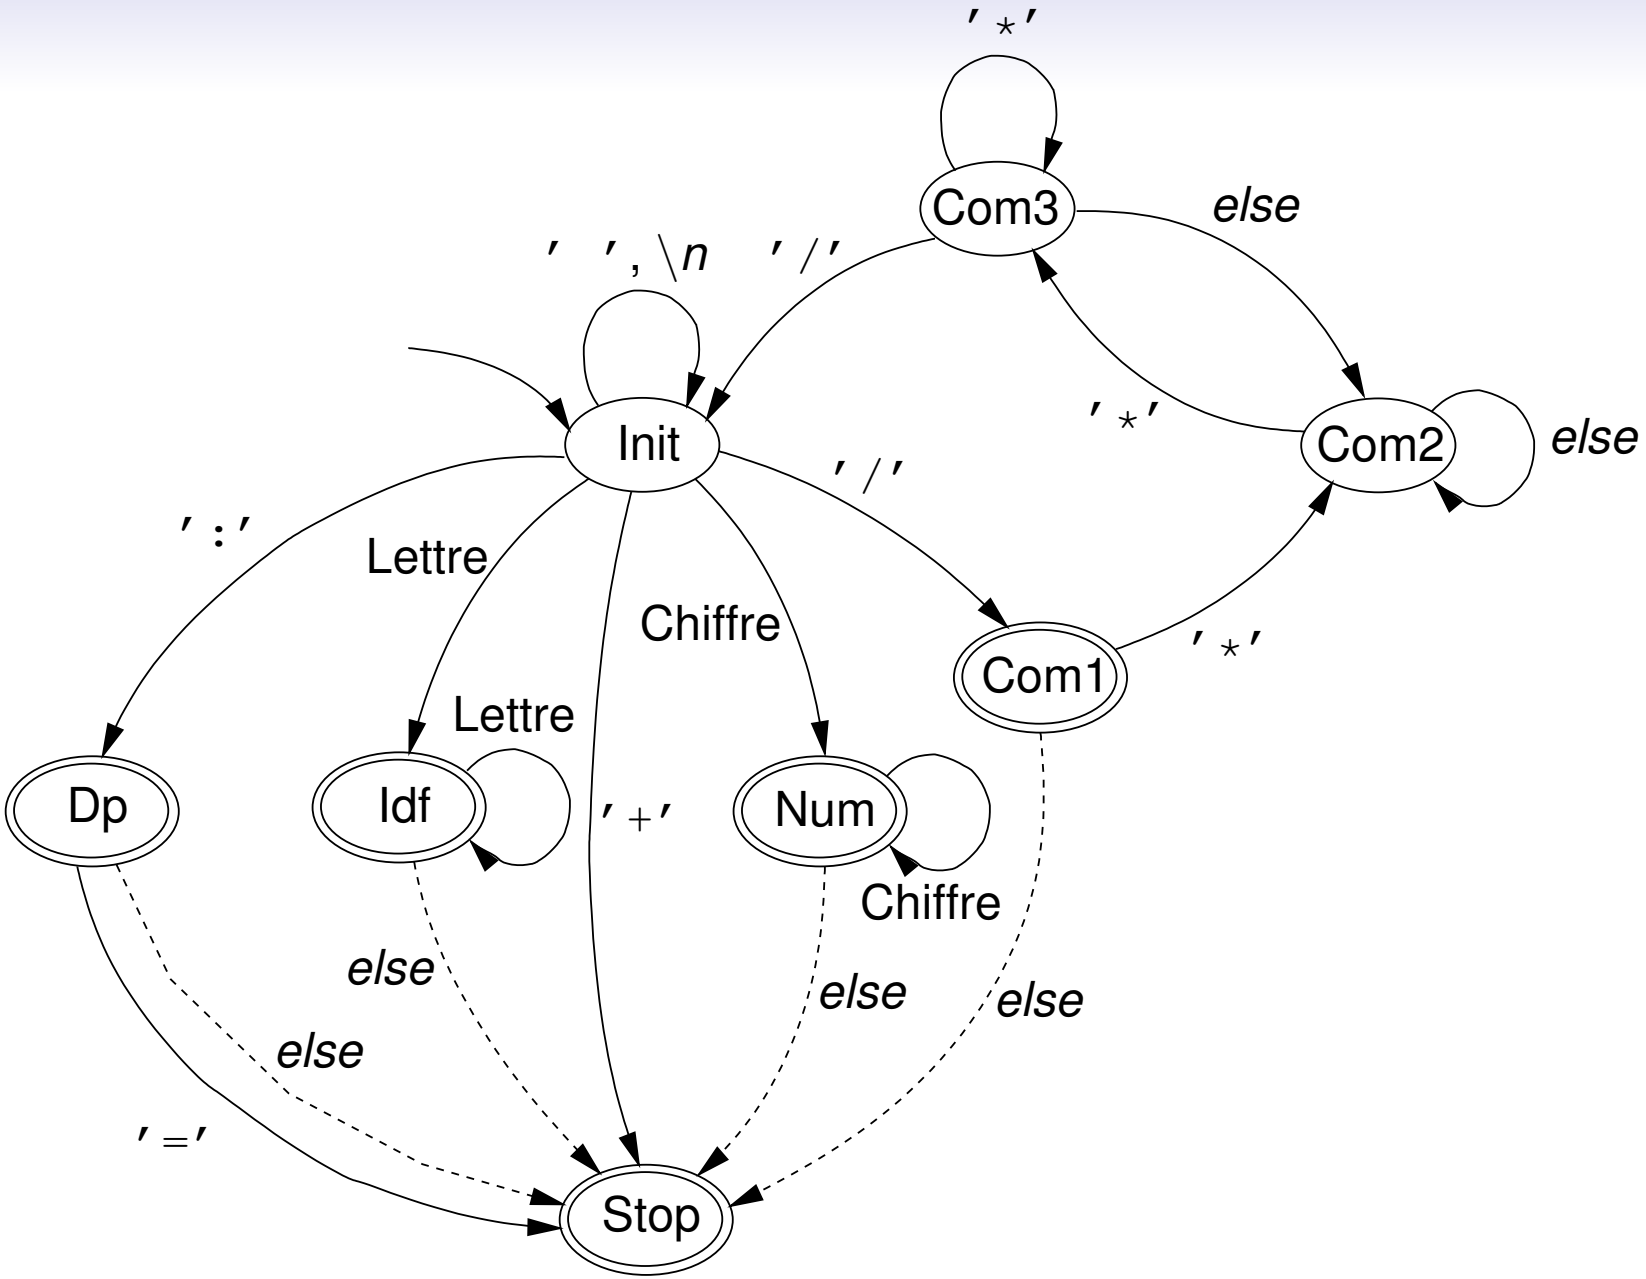
' *'
Com3
else
' ', \n
'/'
Init
'*'
Com2
else
':'
Lettre
'/'
Chiffre
Com1
'*'
Lettre
Dp
Idf
'+'
Num
Chiffre
else
else
else
else
'='
Stop

Exemple (Suite)

unité lexicale : chemin entre l'état initial *Init* et un état acceptant.

L'état acceptant est *Stop*, mais aussi *Dp*, *Idf*, *Num* et *Com1* si il n'y a pas de caractère suivant (fin du fichier).

On ajoute un lexème d'erreur, qui est renvoyé si aucun lexème n'est reconnu.

```
int Num_LC, Num_CC; char C; Lexeme LC;
public void lex_suiv() {
  boolean Passer_au_suivant; Etat cour = Init;
  while (cour != Stop && cour != Erreur && !EOF()) {
    switch (Etat_cour) {
      case Init: ...
      case Dp: ...
      case Com1: ...  Mise a jour de cour
      case Com2: ...  selon la valeur de C
      case Com3: ...
      case Idf: ...
      case Num: ...
      default : break;
    }
    if (Passer_au_suivant) {Car_Suiv();}
  }
  if (EOF()) {
    if (cour==Init) {LC.code = Eof}
    else if (cour==Com2||cour==Com3) {LC.code=Erreur}}
}
```

En pratique

En pratique, de nombreux outils existent pour générer automatiquement des analyseurs lexicaux.

Exemple :

- C : flex
- Java : jflex
- Ocaml : ocamllex
- ...

```
%{
#include <stdlib.h>
#include "global.h"
%}
blancs    [ \t]+
chiffre   [0-9]
entier    {chiffre}+
exposant  [eE][+-]?{entier}
reel
{entier}("."{entier})?{exposant}?
%%
{blancs}  { /* On ignore */ }
{reel}    { yylval=atof(yytext);
            return(NOMBRE);}
"+"   return(PLUS);
"-"   return(MOINS);
"*"   return(FOIS);
"/"   return(DIVISE);
"^"   return(PUISSANCE);
"("   return(PARENTHESE_GAUCHE);
")"   return(PARENTHESE_DROITE);
"\n"  return(FIN);
```