Optimisations

CS410 - Langages et Compilation

Julien Henry
Catherine Oriat

Grenoble-INP Esisar

2012-2013

Summary

Optimisations : challenge

Idéalement, la compilation d'un programme d'un langage vers un autre doit :

- Eliminer le coût des abstraction du langage d'entrée (de plus haut niveau)
- Utiliser les forces du langage cible : en assembleur, instructions spéciales, etc.

Différentes contraintes

On peut imposer différentes contraintes au code produit :

- Code le plus rapide
- Code le plus compact
- Code le plus proche du source (débugage)
- ...

L'optimisation permet de transformer le code (ou la structure de données représentant le code) pour atteindre l'un de ces objectifs.

Pourquoi étudier les optimisations ?

C'est important de comprendre ce que le compilateur va faire du code qu'on lui donne en entrée :

- Comprendre l'impact possible de l'optimisation sur sa production de code.
- Comprendre l'impact sur la taille du code (important en embarqué lorsqu'on a très peu de mémoire).
- Comprendre un certain nombre d'optimisations courantes et leurs conséquences.

Phases d'optimisations

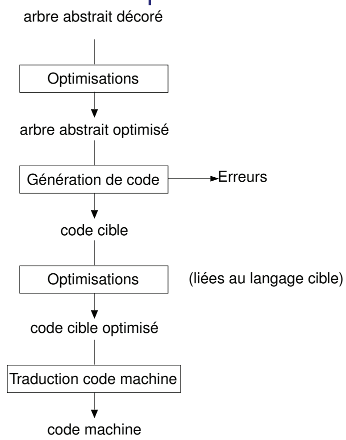

Optimisations 1

Après avoir construit l'arbre abstrait du programme et l'avoir décoré :

- Richesse maximale d'informations
- Identification et fusion de code
- Transformations de la structure du programme
- Déplacement/suppression d'instructions
- etc.

Optimisations 2

Optimisations liées au langage cible utilisé :

- Sélection d'instructions
- Optimisations locales des séquences d'instructions
- etc.

Exemples d'optimisations d'un compilateur moderne

Optimisations 1 :

- Inlining de fonctions
- Eliminination de code mort
- Optimisation des boucles imbriquées
- Transformation de boucles (déroulement, fusion, etc)
- propagation de constantes
- ...

Optimisations 2 :

- Conversion des conditionnelles
- Déplacement de code
- Allocation des registres
- Optimisation par fenêtre

Exemple d'optimisations 1 : l'inlining

Optimisation très courante :
Remplace un appel de fonction par le code de la fonction :

- Pas d'appel de fonction donc :
  - Pas de gestion de pile
  - Pas de passage de paramètres
  - Meilleure optimisation du code localement
  - Prédiction des processeurs meilleure
- Mais : augmentation de la taille du code

L'inlining

- est sûr : le comportement du code après inlining doit être équivalent au code avant inlining
- doit à priori apporter un gain de vitesse
- est opportun pour les fonctions de petite taille ou appelées à un seul endroit du code.

Exemple d'optimisations 2 : optimisation par fenêtre

- On génère dans un premier temps de l'assembleur non optimisé
- On fait une passe sur cet assembleur généré en optimisant localement dans une fenêtre

Exemple :

```
a = b + c ;
d = a + e ;
```

```
MOV b, R0
ADD c, R0
MOV R0, a
MOV a, R0
ADD e, R0
MOV R0, d
```

```
MOV b, R0
ADD c, R0
MOV R0, a
ADD e, R0
MOV R0, d
```


Summary

Analyses nécessaires

De nombreuses optimisations recquièrent des analyses **statiques** sur le code :

- Pour supprimer le code mort, il faut faire une analyse statique le détectant.
- Pour allouer les registres de façon optimisée, il faut connaître les variables **vivantes**.
- etc.

On effectue ces analyses sur le **Graphe de flot de contrôle** du programme.

Graphe de flot de contrôle

Représentation du programme sous forme de graphe :

- Les états sont les différents points du programme (instructions)
- Les arcs sont les transitions élémentaires entre 2 instructions qui peuvent s'exécuter à la suite.
- Un état a 0, 1 ou 2 arcs sortants (0 si état final, 2 si l'instruction est un branchement conditionnel et 1 sinon)

Ce graphe s'appelle un **graphe de flot de contrôle (CFG)** : il respecte et permet de travailler sur l'ordre d'exécution du programme.

Exemple

```
x = 0;
y = 0;
while (true) {
  if (x <= 50)
    y++;
  else
    y--;

  if (y < 0) break;
  x++;
}
```

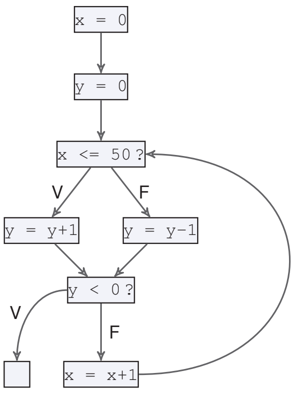

Blocs de base

En pratique, les états du graphe de flot de contrôle ne sont pas de simples instructions, mais une suite d'instructions qui s'exécutent nécessairement à la suite (sans saut).
Ces états s'appellent des **blocs de base**.

Exemple de CFG

LLVM est l'infrastructure de compilateur utilisée par Apple.

```
int f() {
  int i = 0;
  int j = 0;

  while (i < 100) {
    j = 0;
    while (j < 100) {
      j++;
    }
    i++;
  }
  return i+j;
}
```

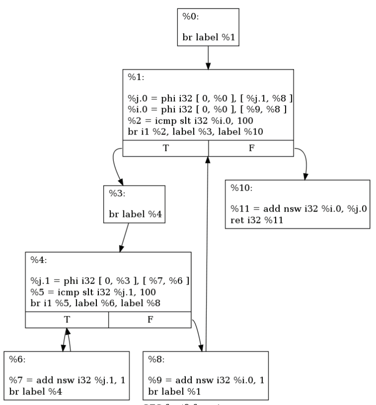

CFG for 'f' function

Détection de code mort

Trouver les blocs de base inaccessibles :

- Soit I le bloc de base initial du programme.
- Soit B un bloc de base dans le graphe
- B est un bloc mort si il n'existe aucun chemin valide dans le graphe entre I et B.

Exemple :

- Si tous les chemins entre le bloc initial et le bloc B passent par les branchements $(i < 100) = T$ et $(i == 100) = T$, alors le bloc B n'est pas atteignable.
- Très souvent, ce n'est pas aussi simple et il faut faire une analyse statique plus avancée pour espérer découvrir du code mort.

Simplifications du graphe

Branchement conditionnel vers le même bloc :

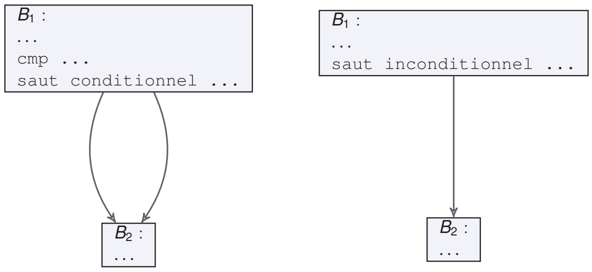

Simplifications du graphe

Suppression d'un bloc vide :

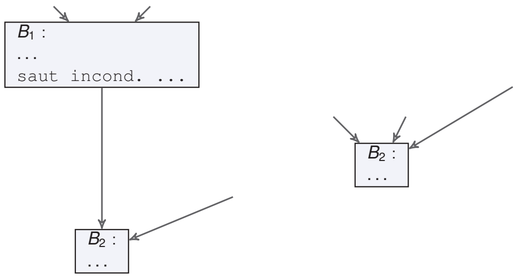

- B_1 est un bloc vide (sans instruction)
- se produit suite à des optimisations dans B_1

Simplifications du graphe

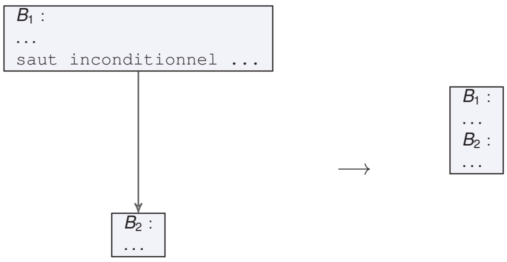

- B_1 et B_2 non vides
- B_1 a un saut inconditionnel vers B_2
- B_2 a un seul antécédent (qui est B_1)

Variables vivantes (Live)

Certaines optimisations s'appuient sur la définition de variable **vivante** :

Definition

Une variable est vivante en un point du programme (une instruction) si sa valeur peut être utilisée par la suite.

Exemple :

```
int x = 12;
... (x vivante)
y = x*2;
... (x non vivante)
```

```
int x = 12;
... (x non vivante)
x = f(5);
y = x*2;
... (x non vivante)
```


Optimisations sur les variables vivantes

Principales optimisations liées à la notion de variables vivantes :

- Pour l'allocation de registres, on s'appuie sur les variables vivantes en un point du programme pour choisir les variables que l'on garde en registre.
- On peut éliminer du code inutile si on se rend compte qu'une variable qui reçoit une affectation est morte.

Calcul des variables vivantes

Pour déterminer l'ensemble des variables vivantes à un point du programme, il faut connaître :

1. Les points de **définition** des variables : endroits où elles sont affectées.
2. Les points d'**utilisation** de ces variables : endroits où on utilise leurs valeurs.

Il est essentiel de pouvoir naviguer facilement entre les utilisations des variables. La représentation intermédiaire du programme inclut donc une chaîne **def-use** : pour une définition de variable, on a la liste de toutes ses utilisations.

Exemple : def-use chaîne

def

x = 12 ;
...
y = x + 6 ;
...
k = x *2 ;

def

...
x = f(x) ;
...
k = x *4 ;

Elimination de code inutile

Si, en calculant les **def-use** chaînes, on obtient des chaînes sans utilisations, alors on peut optimiser en supprimant la définition.

Remarque : ceci n'est vrai que si la définition n'a pas d'effets de bord.

Variables vivantes

Definition

Une variable x est **vivante** à un point I du programme (instruction) si il existe un chemin dans le CFG entre la définition de x et une utilisation de x (dans la même <u>def-use</u> chaîne) qui passe par I.

Exemple

def

x = 12 ;
...
y = x + 6 ;
...
k = x *2 ;
...
z = f(x) ;

def

. . .   ici, x est morte

x = 42 ;
...
k = x *4 ;

Calcul de l'ensemble des variables vivantes

L'analyse des variables vivantes est en fait **approximative** :

- On vérifie s'il existe dans le CFG un chemin menant vers un site d'utilisation, mais on ne se demande pas à quelle condition ce chemin est faisable en réalité.

En conséquence :

- **vivante** signifie en fait <u>potentiellement vivante</u>
- **morte** signifie <u>morte de façon certaine</u>.

Au pire, on a donc le droit de dire que toutes les variables sont vivantes : les optimisations seront alors très inefficaces mais correctes. . .

Propagation de constantes

Une optimisation possible est la **propagation de constantes** :

- On prend une **def-use** chaîne.
- On remplace chaque utilisation par la définition.

def

x = 12 ;
...
y = x + 6 ;
...
k = x *2 ;
...
z = f(x) ;

def

~~x = 12~~ ;
...
y = 12 + 6 ;
...
k = 12 *2 ;
...
z = f(12) ;

Summary

Optimisation des boucles

De très nombreuses optimisations peuvent être faites sur les boucles :

- Pour optimiser l'utilisation du cache
- Pour ne pas répéter inutilement des calculs dans la boucle
- ...

Les quelques slides suivants présentent un certain nombre d'optimisations possibles sur les boucles.

Fusion de boucles

```
for (int i = 0; i < 50; i++) {
        t[i] = t[i] + 1;
}
...
for (int i = 0; i < 50; i++) {
        u[i] = u[i] + 1;
}
```

Transformé en :

```
for (int i = 0; i < 50; i++) {
        t[i] = t[i] + 1;
        u[i] = u[i] + 1;
}
```


Changement de l'ordre des boucles imbriquées

Principe de localité : éviter les cache-miss

```
for (int i = 0; i < 50; i++) {
        for (int j = 0; j < 100; j++) {
                t[i][j] = t[i][j]+1;
        }
}
```

Transformé en :

```
for (int j = 0; j < 100; j++) {
        for (int i = 0; i < 100; i++) {
                t[i][j] = t[i][j]+1;
        }
}
```

Dépend de l'architecture (technique de cache) et disposition du tableau dans la mémoire.

Loop unwiding

```
for (int i = 0; i < 50; i++) {
         f(i);
}
```

Transformé en :

```
for (int i = 0; i < 50; i+=5) {
         f(i);
         f(i+1);
         f(i+2);
         f(i+3);
         f(i+4);
}
```

- 5 fois moins de tests / branchements
- code 5 fois plus grand (en taille)...

Loop unswitching

```
  for (int i=0; i<1000; i++) {
    x[i] = x[i] + y[i];
        if (w) { y[i] = 0 };
  }
```

Transformé en :

```
if (w) {
  for (int i=0; i<1000; i++) {
    x[i] = x[i] + y[i];
    y[i] = 0;
  }
} else {
  for (int i=0; i<1000; i++) {
    x[i] = x[i] + y[i];
    y[i] = 0;
  }
}
```

Summary

Intro

Dans les compilateurs modernes, on commence par séléctionner les instructions assembleur que l'on va utiliser, en considérant qu'on a un nombre infini de registres.
On obtient alors une représentation intermédiaire appelée ERTL.

Exemple : factorielle

```
procedure f(1)
var %0,%1,%2,%3,%4,%5,%6
entry f11
f11: newframe            →f10
f10: move %6, $ra        →f9
f9 : move %5, $s1        →f8
f8 : move %4, $s0        →f7
f7 : move %0, $a0        →f6
f6 : li %1, 0            →f5
f5 : blez %0             →f4,f3
f3 : addiu %3, %0, -1 →f2
f2 : j → f20
f20: move $a0, %3    →f19
f19: call f(1)       →f18
f18: move %2, $v0    →f1
f1:  mul %1, %0, %2 →f0
f0:  j               →f17
f17: move $v0, %1    →f16
f16: move $ra, %6    →f15
f15: move $s1, %5    →f14
f14: move $s0, %4    →f13
f13: delframe        →f12
f12: jr $ra
f4:  li %1, 1        →f0
```


Exemple : factorielle, après analyse des variables vivantes

```
procedure f(1)
var %0,%1,%2,%3,%4,%5,%6
entry f11
f11: newframe          →f10    $a0, $s0, $s1, $ra
f10: move %6, $ra      →f9     %6, $a0, $s0, $s1
f9 : move %5, $s1      →f8     %5, %6, $a0, $s0
f8 : move %4, $s0      →f7     %4, %5, %6, $a0
f7 : move %0, $a0      →f6     %0, %4, %5, %6
f6 : li %1, 0          →f5     %0, %4, %5, %6
f5 : blez %0           →f4,f3  %0, %4, %5, %6
f3 : addiu %3, %0, -1 →f2      %0, %3, %4, %5, %6
f2 : j → f20                   %0, %3, %4, %5, %6
f20: move $a0, %3   →f19       %0, %4, %5, %6, $a0
f19: call f(1)      →f18       %0, %4, %5, %6, $v0
f18: move %2, $v0   →f1        %0, %2, %4, %5, %6
f1:  mul %1, %0, %2 →f0        %1, %4, %5, %6
f0:  j              →f17       %1, %4, %5, %6
f17: move $v0, %1   →f16       %4, %5, %6, $v0
f16: move $ra, %6   →f15       %4, %5, $v0, $ra
f15: move $s1, %5   →f14       %4, $v0, $s1, $ra
f14: move $s0, %4   →f13       $v0, $s0, $s1, $ra
f13: delframe       →f12       $v0, $s0, $s1, $ra
f12: jr $ra
f4:  li %1, 1       →f0      %1, %4, %5, %6
```


Interférence

- On a maintenant un ensemble de pseudo-registres %0, %1, ... auxquels il faut associer un vrai registre.
- On connaît les propriétés de vivacité de chaque pseudo-registre.

Question : Quels sont les pseudo-registres qui peuvent être associés au même registre ?

Definition

Deux pseudo-registres peuvent être associés au même registre si ils n'**interfèrent** pas : on n'écrit jamais dans l'un si l'autre est vivant.

Les instructions **move** fournissent des emplacements préférentiels (pour essayer de les supprimer).

Graphe d'interférence

On construit pour l'allocation de registres un graphe d'interférences :

- Les sommets sont les pseudo-registres
- Les arêtes représentent les relations d'interférence
- Les arêtes en pointillé représentent les arêtes de préférence (lorsqu'on a une instruction **move %0, %1**, on choisit de préférence d'associer le même registre à %0 et %1)

Exemple : graphe d'interférence pour factorielle

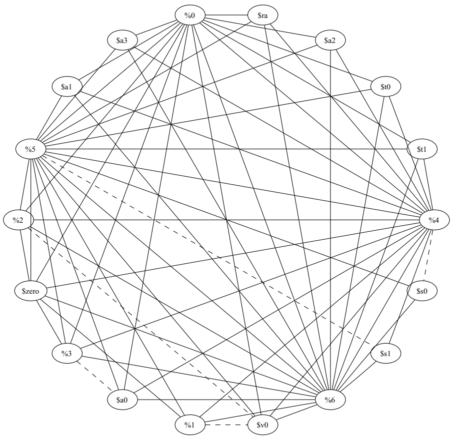

Coloriage du graphe d'interférence

Supposons que l'on dispose de k registres dans notre architecture cible. Le problème de l'allocation de registre se réduit à :

- Soit k couleurs différentes.
- Attribuer une couleur à chaque sommet du graphe d'interférence (pseudo-registre), tel que
  1. deux sommets reliés par une arête d'interférence n'ont jamais la même couleur.
  2. si possible, deux sommets reliés par une arête de préférence sont de même couleur.

Si une solution à ce problème existe, on dit que le graphe est k-colorable. Sinon, notre programme devra utiliser des variables temporaires sur la pile (**spill**)...

Difficultés et limitations

Premier problème :

- Le problème de coloriage de graphe est **NP-complet**, donc impossible en pratique de colorier le graphe de façon optimale.

On s'appuie donc sur des heuristiques pour colorier le graphe de façon linéaire ou quasi-linéaire.

Difficultés et limitations

Deuxième problème :

- Si le graphe n'est pas k-colorable, ou si on ne trouve pas de k-coloriage, que faire ?

On laisse certains sommets non coloriés. Les sommets non-coloriés seront des pseudo-registres qui seront en fait placés dans la pile et non pas de façon permanente dans un registre.

Difficultés et limitations

Troisième problème :

- Sur certaines architectures, les registres ne sont pas tous interchangeables.

Exemple : sur les Motorola 68k, l'instruction d'addition accepte un registre d'**adresse** ou de **données** en tant qu'opérande, mais l'instruction de multiplication n'accepte qu'un registre de **données**.

Dans ce cas, il faut adapter l'algorithme de coloration...

Un algorithme de coloriage

Algorithme de Chaitin :

- Un sommet s de degré strictement inférieur à k est **trivialement colorable** : le graphe G est k-colorable si et seulement si $G \setminus \{s\}$ est k-colorable.
- On peut répéter cette simplification autant de fois que possible.
- Après simplification, de nouveaux sommets peuvent devenir **trivialement colorables**.

Un algorithme de coloriage

Algorithme de Chaitin :

procedure COLORIER (G)
    Si le graphe G n'a aucun sommet alors terminer
    Si il existe un sommet s trivialement colorable :
        COLORIER $(G \backslash \{s\})$
        Attribuer une couleur disponible à s
    Sinon
        Choisir un sommet s
        COLORIER $(G \backslash \{s\})$
        Spiller s

Un algorithme de coloriage

Problème **NP-complet** $\Rightarrow$ on utilise des **heuristiques** !

Le choix des sommets à **spiller** est très important :

- Il faut spiller les registres **peu utilisés** ou utilisé en des points non critiques du code (hors boucle, etc).
- Pour faciliter la suite du coloriage, il vaut mieux choisir un sommet de fort degré pour faire baisser le degré des autres...

On crée donc une fonction de coût qui utilise ces critères.

Exemple

Pour $k = 2$, que donne l'algorithme de coloriage ?

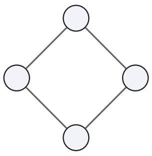

Comment améliorer l'algorithme ?

Un algorithme de coloriage

Algorithme de Chaitin :

procedure COLORIER (G)
    Si le graphe G n'a aucun sommet alors terminer
    Si il existe un sommet s trivialement colorable :
        COLORIER $(G \backslash \{s\})$
        Attribuer une couleur disponible à s
    Sinon
        Choisir un sommet s
        COLORIER $(G \backslash \{s\})$
        Si une couleur est disponible pour s
            la lui attribuer
        Sinon
            Spiller s